

Actividad de Seguimiento # 6
Probabilidad y Estadística
Bioingeniería, 2026-1

Se cuenta con una base de datos con información clínica y demográfica de 8763 pacientes, y se encuentran clasificados según han o no padecido infarto cardiaco, con lo cual se pretende encontrar un modelo que sea capaz de predecir a partir de esa información clínica y demográfica si un paciente está en riesgo de padecer un infarto cardiaco.

Procedimiento

1. Cargue la base de datos. Elimine las columnas.

```
'Patient ID'  
'Blood Pressure'  
'Country'  
'Continent'  
'Hemisphere'
```

2. Realice una codificación one_hot con la siguiente función, para las variables categóricas restantes:

```
data_encoded = pd.get_dummies(data, columns=['Sex', 'Diet'],  
                               drop_first=False, dtype=int)
```

3. La variable y será la columna 'Heart Attack Risk', guárdela en un array llamado y, las demás variables guárdelas en un array X.
4. Con la siguiente función separe los datos en entrenamiento y prueba:

```
X_train, X_test, y_train, y_test = train_test_split(X, y,  
                                                    test_size=0.3, random_state=42)
```

Ahora se intentará la construcción de 3 modelos de clasificación diferentes para seleccionar el mejor: Un modelo de regresión logística, un KNN y un Random Forest.

5. Realice la construcción del modelo de regresión logística y evalúelo usando validación K-folds, use la(s) métrica(s) de validación que considere apropiada(s).
6. Ahora genere un modelo KNN y determine con curvas de validación el valor más apropiado de número de vecinos. Para esto debe usar la(s) métrica(s) de validación que considere apropiada(s) según el contexto. Luego de encontrado el valor de K, corrobore el desempeño usando validación k-folds.

7. Ahora genere un modelo RandomForest y determine con curvas de validación el mejor número de árboles Para esto debe usar la(s) métrica(s) de validación que considere apropiada(s) según el contexto. Recomendación: varíe el número de árboles entre 5 y 95 en pasos de 10. Genere el modelo con el mejor número de árboles y corrobore el desempeño usando validación k-folds.
8. Según las métricas obtenidas ¿cuál de los modelos es mejor según el contexto? y ¿por qué?

Entregable

Entregue un archivo .ipynb, en el cual utilice celdas de código y de texto para dar respuesta a las preguntas, describir los procedimientos hechos, y analizar los resultados. Recuerde ser muy descriptivo, y no programar todo o mucho en una misma celda de código, se insta a programar bloques cortos y explicarlos bien.